

KOCAELİ ÜNİVERSİTESİ

MÜHENDİSLİK FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



Endüstriyel Ürünlerde Hata Tespiti

Derin Öğrenmenin Temelleri Dersi

Final raporu

220201003 230201040

Burak Çakır Sadık Gölpek

Aralık-2025

ÖZET

Elektronik imalat sanayiinde, Baskılı Devre Kartlarının (PCB) kalitesi, nihai ürünün güvenilirliği için kritik öneme sahiptir. Bu çalışmada, PCB yüzeyindeki altı farklı kusur tipinin (missing_hole, mouse_bite, open_circuit, short, spur, spurious_copper) tespiti için iki farklı derin öğrenme yaklaşımı geliştirilmiş ve karşılaştırılmıştır. Birinci yaklaşım olarak, güncel nesne tespiti mimarisi **YOLOv13**, tüm görüntü üzerinde hem konumlandırma hem sınıflandırma yapmak üzere eğitilmiştir. İkinci yaklaşım olarak, **ResNet-50** mimarisi, koordinat tabanlı veri ön işleme ("Dijital Makas") ve transfer öğrenme (Transfer Learning) stratejileriyle özelleştirilmiş bir sınıflandırıcı olarak kullanılmıştır. Deneysel sonuçlar, YOLOv13'ün gerçek zamanlı tespit yeteneğine sahip olduğunu, ancak küçük nesnelerde zorlandığını; ResNet-50 tabanlı özelleştirilmiş yaklaşımın ise %94 gibi yüksek bir doğruluk oranıyla sınıflandırma başarısında üstünlük sağladığını göstermiştir. Çalışma, endüstriyel kalite kontrol süreçlerinde hibrit yaklaşımların önemini ortaya koymaktadır.

Bu final raporu, projenin motivasyonunu, literatürdeki yerini, seçilen veri setini ve modelin eğitim için yapılandırıldığı metodolojiyi sunmaktadır. Projenin bir sonraki hedefi, bu eğitimi tamamlayarak elde edilecek **mAP (mean Average Precision)**, **Precision (Kesinlik)** ve **Recall (Geri Çağırma)** metriklerini analiz etmek ve modelin endüstriyel kalite kontrol süreçleri için etkinliğini değerlendirmektir.

1.GİRİŞ

Endüstri 4.0 ve akıllı üretim teknolojilerinin hızla yaygınlaşmasıyla birlikte, imalat sanayiinde kalite kontrol (KK) süreçleri, işletmelerin rekabet gücünü ve operasyonel verimliliğini belirleyen en kritik faktörlerden biri haline gelmiştir. Özellikle elektronik imalat sektöründe, akıllı telefonlardan otomotiv sistemlerine kadar sayısız modern cihazın temelini oluşturan Baskılı Devre Kartları (PCB), bu kalite zincirinin merkezinde yer almaktadır. Üretim aşamasında PCB yüzeylerinde meydana gelen; kısa devre (short), açık devre (open circuit), eksik delik (missing hole) veya hat dışı bakır (spurious copper) gibi mikroskobik ve karmaşık kusurlar, nihai ürünün güvenilirliğini, performansını ve güvenliğini doğrudan tehdit ederek ciddi mali kayıplara, ürün geri çağırımlarına ve marka itibarının zedelenmesine yol açabilmektedir.

Geleneksel kalite kontrol yaklaşımları, büyük ölçüde manuel görsel denetime dayanmaktadır. Ancak bu yöntemler, günümüzün yüksek hacimli ve yüksek yoğunluklu üretim hatlarının hızına ve karmaşıklığına yanıt verememektedir. Manuel denetim; yavaş, maliyetli, subjektif olmasının yanı sıra, özellikle uzun çalışma saatleri sonucunda operatör yorgunluğuna bağlı olarak yüksek hata oranlarına (gözden kaçırma veya yanlış tespit) son derece açıktır. Bu zorlukların üstesinden gelmek amacıyla, son yıllarda bilgisayarla görme ve derin öğrenme tabanlı Otomatik Optik Denetim (AOI) sistemleri kritik bir çözüm olarak öne çıkmıştır.

Bu alanda iki temel derin öğrenme paradigması dikkat çekmektedir. Bir yanda, "**You Only Look Once**" (**YOLO**) gibi tek aşamalı (single-stage) nesne tespiti algoritmaları, endüstriyel denetim için gereken yüksek hız (gerçek zamanlı performans) ve tespit başarısı arasındaki dengeyi sunarak hatanın hem yerini hem türünü anlık olarak belirleyebilmektedir. Diğer yanda, **ResNet (Residual Networks)** gibi derin mimarili sınıflandırma ağları, transfer öğrenme (transfer learning) yetenekleri ve derinlemesine öznetelik çıkarımı sayesinde, hataya odaklanıldığında çok daha yüksek hassasiyetle sınıflandırma yapabilme potansiyeline sahiptir. Endüstriyel bir problemin çözümünde, "nesne tespiti" ile "özelleştirilmiş sınıflandırma" yaklaşımlarının kıyaslanması, en doğru mühendislik çözümünü bulmak adına kritik öneme sahiptir.

Bu projenin temel amacı, modern derin öğrenme yaklaşımlarından faydalanarak PCB kusur tespiti için iki farklı metodolojiyi geliştirmek, eğitmek ve karşılaştırmalı olarak değerlendirmektir. Bu kapsamda, nesne tespiti kanadını temsil etmek üzere YOLO mimarisinin en güncel varyantı olan **YOLOv13**; sınıflandırma kanadını temsil etmek üzere ise **ResNet-50** mimarisi seçilmiştir. Çalışmada, YOLO'nun tüm görüntü üzerindeki tespit performansı ile ResNet-50'nin koordinat bazlı kırpılmış (cropped) veriler üzerindeki sınıflandırma başarısı, halka açık "PCB Defect Dataset" üzerinde test edilecektir.

Bu rapor, öncelikle problemin tanımını ve motivasyonu ortaya koymaktadır. Takip eden "Literatür Taraması" bölümünde, hem genel endüstriyel hata tespiti hem de PCB özelindeki mevcut akademik çalışmalar incelenmiştir. "Materyal ve Yöntem" bölümünde, veri setinin özellikleri, YOLOv13 için izlenen eğitim stratejisi ve ResNet-50 için uygulanan "Dijital Makas" (veri ön işleme) metodolojisi detaylandırılmıştır. Rapor, her iki modelin eğitim süreci sonunda elde edilen performans metriklerinin (mAP, Accuracy, Recall vb.) kıyaslanacağı ve en uygun çözümün tartışılacağı "Deneysel Sonuçlar" bölümü ile son bulacaktır.

2.LİTERATÜR TARAMASI

Bu bölümde, endüstriyel ürünlerde hata tespiti alanında yapılmış güncel akademik çalışmalar incelenmiştir. Çalışmamızın teorik altyapısını oluşturmak ve önerilecek yöntemin literatürdeki yerini belirlemek amacıyla, tarama iki ana başlık altında toplanmıştır:

- 1- Genel endüstriyel ürünlerde yüzey kusuru tespiti.
- 2- Konu özelinde, Baskılı Devre Kartı (PCB) kusur tespiti.

R Ding., vd 2019 [1] çalışmalarında, elektronik ürünlerin üretiminde temel bir görev olan Baskılı Devre Kartlarında (PCB) bulunan küçük hata tespitini (Tiny Defect Detection - TDD) gerçekleştirmeyi amaçlayan TDD-Net adlı basit ve etkili bir derin öğrenme ağı geliştirmişlerdir. Geleneksel yöntemlerin karmaşık ve çeşitli PCB hatalarıyla başa çıkmadaki sınırlılıklarına çözüm getirmeyi hedefleyen bu çalışma, düşük verimlilik, yüksek yanlış ve eksik tespit oranları gibi sorunların üstesinden gelmek için derin öğrenme algoritmalarını ve Özellik Piramidi Evrişimli Ağları (Feature Pyramid ConvNets) uygulamıştır. TDD-Net, özellikle küçük hataların tespitini iyileştirmek üzere yenilikçi bir yaklaşımla tasarlanmıştır. Bu yaklaşım, öncelikle ağı doğal çok ölçekli hiyerarşilerinden yararlanarak özellik piramitleri oluşturmakta ve böylece küçük hata tespiti için kritik olan düşük seviyeli yapısal bilgileri etkin bir şekilde yakalamaktadır. Buna ek olarak, hataların doğru konumlandırılması için K-means kümeleme yöntemiyle makul çapalar (anchors) tasarlanarak daha yüksek Kesişim Üzeri Birleşim (IoU) skorlarına ulaşılmıştır. Son olarak, küçük ve dengesiz veri kümesi sorununa karşı, eğitim aşamasında Çevrimiçi Zor Örnek Madenciliği (OHEM) tekniği kullanılarak İlgi Alanı Önerilerinin (ROI) kalitesi artırılmıştır. Önerilen TDD-Net yöntemi, PCB hata veri seti üzerinde yapılan kapsamlı deneylerde %98.90 mAP (ortalama kesinlik) değerine ulaşarak güncel en iyi yaklaşımlardan daha iyi sonuçlar elde etmiştir. Bu sonuç, yöntemin hızlı ve güvenilir bir kalite kontrol yaklaşımı sunduğunu ve kumaş veya alüminyum yüzey denetimi gibi diğer alanlara da kolayca genişletilebileceğini göstermektedir.

Al-Jumaili., vd 2025 [2] çalışmalarında, dijital endüstriyel ürünlerin geliştirilmesinde yapay zekanın (AI) kalite kontrol ve hata tespiti süreçlerini nasıl dönüştürdüğü incelenmiştir. Geleneksel tasarım ve üretim süreçlerindeki insan hatası gibi kısıtlamalara çözüm olarak, makine öğrenimi algoritmaları ve örüntü tanıma (pattern recognition) yeteneklerine odaklanan AI-destekli modeller (AI-driven models) kullanılmıştır. Deneysel analizler, önerilen yapay zeka yaklaşımlarının, geleneksel manuel denetim (conventional manual inspection) yöntemlerine kıyasla belirgin şekilde üstün olduğunu göstermiştir. Sonuç olarak, "etkileyici bir tespit oranı" (impressive detection rate) elde edilmiş ve "hata oranında önemli bir azalma" (significant reduction in defect rate) sağlanmıştır. Bu bulgular, AI tabanlı sistemlerin kalite yönetimi için daha istikrarlı ve verimli bir çözüm sunduğunu doğrulamaktadır.

Hsu.,vd 2025 [3] çalışmalarında, endüstriyel ürün denetiminde yeni ürünler için gereken zaman alıcı etiketleme ve yeniden eğitim sorunlarına çözüm olarak Defect-Aware SAM (DA-SAM) adlı bir yaklaşım sunulmuştur. Bu yöntem, SAM mimarisini LoRA adaptörleri ve

kutu istemleri (box prompts) ile birleřtirerek, iki ařamalı bir eęitim stratejisi kullanır. alıřmada ayrıca, karmařık arka planlarda kk kusurlar ieren Spingence Tiny Defect (SPTD) adında yeni bir veri seti de tanıtılmıřtır. MVTec AD ve SPTD veri setleri zerinde yapılan deęerlendirmelerde, DA-SAM sıfır-ęrenme (zero-shot) senaryosunda hedef veri setinde yeniden eęitime ihtiya duymadan (plug-and-play) 87.8 Piksel seviyesinde AUROC elde etmiřtir. Az-rnekle ęrenme (few-shot) testlerinde ise, geleneksel UNet modelleri yakınsayamazken, DA-SAM sadece beř-rnekli (five-shot) eęitimle %76.1 AUROC'a ulařarak ok az veriden etkili bir řekilde ęrenebildięini ve denetim srelerini nemli lde hızlandırabildięini kanıtlamıřtır.

Butolo., 2024 [4] alıřmaları, MULTI-AI projesi kapsamında, endstriyel rnlerde oklu-materyal ve oklu-hata (yzey, morfoloji, grnm) tespiti yapabilen, lklenebilir bir anomali tahmin sistemi nermektedir. Bu alıřma, farklı denetim istasyonlarına olan ihtiya ortadan kaldırmayı amalayan ve grnt iřleme tekniklerini sezgisel bir kullanıcı arayz ile birleřtiren zel bir zm sunmaktadır. nerilen metodoloji, zellikle halka (annular) řekillerin denetimine gl bir řekilde odaklanmıřtır. Algoritma, nce iki eř merkezli daireyi (concentric circles) tanımlayarak alıřır ve ardından bu daireler arasında kalan halka řeklindeki blgeyi (annular region) tarar. Bu blgedeki kusurlar, nceden tanımlanmıř bir "beklenen norm" (rneęin "siyah" bir aralık) renk deęerinden sapma gsteren piksellerin tespit edilmesiyle tanımlanır. alıřma, bu sistemi bir zm olarak sunmakta olup, gelecekteki planlar arasında sistemin plastik mikro enjeksiyonlu paralar ve metal paralar gibi iki farklı kullanım senaryosu zerinde test edilmesi ve yarı denetimli etiketleme ile aktif ęrenme (active learning) yeteneklerinin geliřtirilmesi bulunmaktadır.

Li., vd 2023 [5] alıřmalarında, endstriyel rn yzeylerindeki kusur tespitinde, zellikle kk hedef tespiti (small target detection) kabiliyetini artırmak ve zayıf kusur konumlandırma (poor defect location) sorununu zmek amacıyla YOLOV5 algoritması zerinde yeniliki iyileřtirmeler nerilmiřtir. Geleneksel YOLOV5'in K-Means algoritmasına dayalı aday ereve (anchor box) belirleme ynteminin yetersizliklerini ařmak iin, ayrıık noktaların (discrete points) etkisini ortadan kaldıran K-Means++ algoritması kullanılmıřtır. Buna ek olarak, modele ARM, BFF ve ODM modlleri entegre edilerek, gerek aday erevelerle dřk keřiřim alanına sahip rneklelerin filtrelenmesi ve ereve boyutlarının otomatik olarak optimize edilmesi saęlanmıřtır. Algoritma modelinin kresel znitelik ıkarma (global feature extraction) ve kk hedef tespiti yeteneklerini kkten iyileřtirmek amaıyla, YOLOV5'in backbone aęının son kısmı (tail) bir Transformer kodlayıcı (encoder) modeli ile deęiřtirilmiřtir. Yapılan testler sonucunda, modifiye edilen algoritma %70.3 ortalama doęruluk (average accuracy) elde etmiř; bu, %65.6 olan orijinal YOLOV5 modeline kıyasla %4.7'lik belirgin bir performans artıřını temsil etmektedir. Tespit hızında hafif bir dřř yařanmasına raęmen, iyileřtirilmiř modelin test veri seti zerinde kk hedefleri tespit etmede ve hedeflerin konumunu belirlemede ok daha stn bir yetenek sergiledięi kanıtlanmıřtır.

Huang vd., 2023 [6] alıřmalarında, endstriyel yzey hata tespitinde piksel bazlı etiketlemenin (pixel-wise labeling) yksek maliyetli olması sorununa ynelik, yalnızca grnt seviyesinde etiketler (image-level labels) gerektiren yeni bir zayıf denetimli

(weakly-supervised) yöntem sunulmuştur. Önerilen üç aşamalı (sınıflandırma, CAM oluşturma/iyileştirme, segmentasyon) yaklaşım, Sınıf Aktivasyon Haritalarının (CAM) hedef nesneyi eksik (under-activation) ve arka planı aşırı aktive (over-activation) etme sorununu çözmeyi hedeflemiştir. Bu sorunu aşmak için, denklik düzenlileştirme ve piksel bağlamı korelasyon modüllerini içeren SEAM (Self-supervised Equivariant Attention Mechanism) yöntemi kullanılmıştır. Mimari olarak, ilk sınıflandırma aşaması için en yüksek F1 skorunu (%98.34 Micro-F1) veren ResNet-50 tercih edilirken, segmentasyon performansındaki üstünlüğü nedeniyle ikinci aşamadaki CAM ağı için ResNet-38 omurga (backbone) olarak seçilmiştir. Manyetik Karo (MT) Hata Veri Seti üzerinde yapılan deneysel sonuçlar, önerilen yöntemin standart CAM ve Grad-CAM yaklaşımlarına kıyasla daha yüksek segmentasyon doğruluğu elde ettiğini göstermiştir.

Zhu vd., 2022 [7] çalışmalarında, endüstriyel ürünlerin yüzey denetiminde, özellikle manyetik karolar (magnetic tiles) üzerinde karşılaşılan kritik/ölümcül kusurların (fatal defects) gözden kaçırılması (missed detection) sorununun çözümüne odaklanılmıştır. Bu sorunu çözmek için semantik segmentasyon ve nesne tespiti (object detection) birleştiren yenilikçi bir ardışık (tandem) yöntem önerilmiştir. Önerilen yaklaşımda, ürün yüzeyindeki karmaşık dokular ve sınırlar nedeniyle modelin kafasının karışmasını önlemek amacıyla, öncelikle ölümcül kusurların bulunduğu spesifik bölgeyi ayırmak için bir semantik segmentasyon yöntemi ön işleme (preprocessing) modülü olarak uygulanmıştır. Bu segmentasyon ağı, gerçek endüstriyel uygulamalar için tatmin edici bir segmentasyon etkisi yaratarak %90.43 mIoU gibi yüksek bir değere ulaşacak şekilde optimize edilmiştir. Ardından, nesne tespiti algoritması yalnızca bu önceden segmente edilmiş ince bölgesel alan üzerinde çalıştırılmıştır. Karşılaştırmalı test sonuçları, bu ardışık yöntemin ölümcül çatlakların tespit doğruluğunu önemli ölçüde artırdığını ve en kritik bulgu olarak, gözden kaçırma oranını (False Negative) %32.89'dan %7.89'a dramatik bir şekilde düşürdüğünü göstermiştir. Bu çalışma, nesne tespiti görevi için semantik segmentasyonun bir yardımcı modül olarak kullanılmasının etkinliğini doğrulayan ve bu alanda benzeri olmayan bir yaklaşım sunmuştur.

Luo vd., 2023 [8] çalışmalarında, endüstriyel metal levhaların (metal sheets) yüzeylerindeki kusurların tespiti ve konumlandırılması için YOLOX algoritması üzerinde bir iyileştirme önermişlerdir. Çalışmanın temel yeniliği, veri setindeki farklı kusur türlerinin (dört çeşit kusur) dengesiz dağılımı ve az sayıdaki örnek (small number of samples) sorununu ele almaktır. Bu amaçla, kayıp fonksiyonu (loss function) olarak iyileştirilmiş bir Focal Loss kullanılmıştır. Bu iyileştirme, denge parametrelerinin (balance parameters) optimize edilmesini ve ağırlık faktörlerinin (weight factor) eklenmesini içermektedir. Bu sayede, ağı az sayıdaki kusur örneklerini öğrenme yeteneği güçlendirilmiş ve her bir kusur tipine makul bir ağırlık dağılımı yapılarak örnek dengesi sağlanmıştır. Metal levha test veri seti üzerinde yapılan deneyler, iyileştirilmiş YOLOX algoritmasının %91.54 mAP değerine ulaştığını göstermiştir. Bu sonuç, iyileştirilmemiş YOLOX'in %87.82 mAP'lik performansına ve SSD gibi diğer klasik ağlara kıyasla belirgin bir ilerleme kaydetmiştir. Çalışma, önerilen yöntemin endüstriyel metal levha yüzey kusur tespiti görevleri için pratik mühendislik önemine sahip olduğunu doğrulamıştır.

Deng vd., 2025 [9] çalışmalarında, endüstriyel kusur tespitindeki belirsiz özellikler (subtle features) ve sınıf dengesizliği (class imbalance) zorluklarını ele almak için Attention Fused Detector (AF-Det) adlı bir çerçeve önerilmiştir. Bu sistem, "dikkat" mekanizmalarını ikili bir şekilde optimize eder: Birincisi, omurga ağına (backbone) entegre edilen Evrişimli Blok

Dikkat Modülleri (CBAM) ile kilit kusur alanlarına odaklanır. İkincisi, sınıf dengesizliği sorununu çözmek için Focal Loss ve Smooth L1 Loss'u birleştiren hibrit bir kayıp fonksiyonu (mixed loss function) kullanır. Halka açık NEU-DET veri setinde test edilen AF-Det, %81.5 mAP elde ederek ana akım temel modellerden daha iyi performans göstermiş ve zor ayırt edilen kusurların tanınmasını iyileştirmiştir.

Yang vd., 2025 [10] çalışmalarında, alüminyum profil yüzeylerindeki çoklu ölçekli (multiple-scale) kusurları tespit etmek için YOLOv11n modelinin optimize edilmesi hedeflenmiştir. Yüksek parametre ve hesaplama gücü ihtiyacını aşmak için, modelin "boyun" (neck) kısmındaki PANet mimarisi, Bidirectional Feature Pyramid Network (BiFPN) ile güçlendirilmiştir. Özel bir alüminyum profil veri seti üzerinde yapılan deneylerde, önerilen YOLOv11n-BiFPN modeli, orijinal YOLOv11n'in %66.0 mAP'lik sonucunu %69.0 mAP'ye yükseltmiştir. Bu %3'lük doğruluk artışı, parametre sayısında çok az bir artışla elde edilmiş ve model, 454.7 FPS gibi çok yüksek bir tespit hızını korumuştur. BiFPN modifikasyonu, özellikle "scratch" (çizik) gibi zorlu kusur sınıflarının tespitini belirgin şekilde iyileştirmiştir.

Xin vd., 2021 [11] çalışmalarında, tekstil endüstrisindeki kumaş kusur tespiti için iki temel zorluğa odaklanılmıştır. İlk olarak, kusur şekillerindeki büyük değişiklikler (large defect shape changing) sorununu ele almak amacıyla, iyi tasarlanmış aday bölge seçim stratejilerini kullanan yeni bir iki aşamalı (two-stage) model olan Multi-task Cascade R-CNN önerilmiştir. İkinci olarak, farklı kumaş materyallerinden kaynaklanan ciddi derecede dengesiz örnek kategorileri (severely unbalanced sample categories) sorununu çözmek için, yeni bir kayıp tahmini (loss estimation) ve optimize edilmiş öğrenme oranı kullanan geliştirilmiş DSSD (promoted-DSSD) modeli sunulmuştur. Gerçek bir tekstil üretim atölyesinden toplanan veri setleri üzerinde yapılan deneylerde, önerilen Multi-task Cascade R-CNN modeli, standart Cascade R-CNN'in (%85.72) çok üzerinde, %90.11 tespit doğruluğuna ve %4.16 gibi çok düşük bir gözden kaçırma oranına (Missing rate) ulaşmıştır. Benzer şekilde, promoted-DSSD modeli de %86.39 doğruluk ve %6.01 gözden kaçırma oranı ile standart DSSD'den (%77.07) belirgin şekilde daha iyi performans göstermiş ve 33 FPS ile gerçek zamanlı denetim gereksinimlerini karşılamıştır.

2.1. Genel Endüstriyel Hata Tespiti Analizi

İncelenen 10 makale, genel endüstriyel hata tespitinde "her duruma uyan tek bir model" olmadığını, aksine spesifik sorunlara odaklı çözümlerin gerekli olduğunu göstermektedir. YOLO (v5, v10, v11) ve R-CNN tabanlı mimariler en yaygın kullanılan temel modellerdir. Çalışmaların odaklandığı temel sorunlar; (1) Sınıf Dengesizliği (Focal Loss, özel kayıp fonksiyonları ile çözülmeye çalışılan), (2) Küçük ve Belirsiz Kusurlar (CBAM gibi dikkat mekanizmaları ve Transformer eklentileri ile çözülmeye çalışılan), (3) Çoklu Ölçek Tespiti (BiFPN gibi gelişmiş özellik piramitleri ile çözülmeye çalışılan) ve (4) Yüksek Etiketleme Maliyeti (DA-SAM gibi az-örnekle öğrenme veya SEAM gibi zayıf denetimli yöntemlerle çözülmeye çalışılan) olarak öne çıkmaktadır.

2.2. PCB (Baskılı Devre Kartı) Odaklı Hata Tespiti Yöntemleri

Bu başlık altında, projemizin temel odak noktası olan Baskılı Devre Kartları (PCB) üzerindeki spesifik kusurların (kısa devre, açık devre, eksik delik vb.) tespiti için geliştirilmiş yöntemler incelenmiştir.

Xie vd., 2025 [12] çalışmalarında, PCB (Baskılı Devre Kartı) üretimindeki kalite kontrol süreçlerinde, geleneksel manuel denetimin düşük verimliliği ve zayıf doğruluğu gibi kısıtlamalara bir çözüm sunulmuştur. Bu amaçla, YOLOv9 algoritmasına dayalı modern bir PCB kusur tespiti yöntemi önerilmiştir. Önerilen bu yaklaşım, temel olarak Genelleştirilmiş Verimli Katman Toplama Ağı (GELAN) ve Programlanabilir Gradyan Bilgisi (PGI) olmak üzere iki kilit bileşeni entegre etmektedir; bu bileşenler, kilit bilgileri korurken hesaplama verimliliğini ve modelin öğrenme kapasitesini artırmaktadır. Çalışmada, "Missing hole", "Open circuit" (Açık devre) ve "Short" (Kısa devre) gibi altı farklı spesifik kusur tipini içeren bir veri seti üzerinde deneysel karşılaştırmalar yapılmıştır. Elde edilen sonuçlar, önerilen YOLOv9 yönteminin, YOLOv8 algoritmasına kıyasla PCB kusur tespitinde hem daha yüksek tespit doğruluğu (higher detection accuracy) hem de daha üstün gerçek zamanlı performans (real-time performance) sunduğunu kanıtlamıştır. Bu bulgular, yöntemin endüstriyel üretimde güvenilir bir otomatik denetim çözümü olarak geniş uygulama potansiyeline sahip olduğunu göstermektedir.

Yu vd., 2024 [13] çalışmalarında, PCB (Baskılı Devre Kartı) kusurlarının tespiti sırasında karşılaşılan küçük hedef (small targets), çeşitli kusur tipleri ve belirsiz öznitelikler (unclear features) gibi zorluklara odaklanılmıştır. Bu sorunları çözmek için YOLOv8n algoritması temel alınarak YOLO-Bo adlı yeni bir ağ modeli geliştirilmiştir. Çalışmanın temel yeniliği, iki ana modifikasyonu içermektedir: İlk olarak, öznitelik çıkarma ağına (feature extraction network) evrişim (convolution) ve öz-dikkat (self-attention) mekanizmalarını birleştiren bir BotNet modülü eklenmiştir; bu modül, modelin karmaşık arka planlar ve belirsiz detayları anlama yeteneğini artırmıştır. İkinci olarak, veri setinin özelliklerini dikkate alarak modele ek bir küçük hedef tespit başlığı (small target detection head) dahil edilmiş ve böylece küçük kusurları yakalama kabiliyeti güçlendirilmiştir. PKU-Market-PCB açık kaynaklı veri seti üzerinde yapılan deneylerde, önerilen YOLO-Bo modeli %96.8 mAP değerine ulaşmıştır. Bu sonuç, temel YOLOv8n modelinin %92.2 mAP'lık performansına kıyasla %4.6'lık bir doğruluk artışı temsil etmektedir. Ayrıca, modelin geri çağırma (recall) oranı da %6.8 oranında iyileşerek, sistemin gözden kaçırma ve yanlış tespit sorunlarına karşı daha sağlam bir çözüm sunduğu kanıtlanmıştır.

Raj vd., 2024 [14] çalışmalarında, PCB (Baskılı Devre Kartı) denetiminde karşılaşılan küçük ve belirsiz (small and subtle) kusurların tespit zorluklarına odaklanılmıştır. Bu amaçla, YOLOv8 modeli temel alınarak geliştirilmiş bir yaklaşım sunulmuştur. Model, ağ kararlılığını ve yakınsamasını iyileştirmek için He başlatması (He initialization) ve toplu normalleştirme (batch normalization) ile birlikte, daha iyi özellik birleşimi (feature fusion) sağlayan öğrenilebilir bir parametre içerecek şekilde modifiye edilmiştir. En kritik modifikasyon olarak, kayıp fonksiyonu (loss function), özellikle küçük nesne tespitini (small object detection) vurgulayacak ve bu tür küçük kusurları yakalayacak şekilde özel olarak uyarlanmıştır. Kapsamlı bir PCB kusur veri seti üzerinde yapılan deneysel sonuçlarda, önerilen model %96.5 Kesinlik (Precision), %97.4 Geri Çağırma (Recall) ve %98.4 mAP50

değerine ulaşmıştır. Bu performans, %96.4 mAP elde eden Lightweight YOLO ve %96.3 mAP elde eden Faster R-CNN dahil olmak üzere diğer temel modelleri geride bırakarak, endüstriyel uygulamalar için yüksek hassasiyetli ve gerçek zamanlı bir denetim çözümü sunmaktadır.

Yu vd., 2025 [15] çalışmalarında, geleneksel PCB (Baskılı Devre Kartı) kusur tespit yöntemlerinin yetersiz doğruluk, zayıf gerçek zamanlı performans ve donanım bağımlılığı sorunlarına çözüm olarak YoloV11 modeli temel alınarak YOLOV11-DAM adlı yeni bir model önerilmiştir. Bu model, üç temel iyileştirme içermektedir: 1) Farklı ölçeklerdeki özellikleri esnek bir şekilde uyarlamak için geliştirilmiş bir derin ayrık genişletilmiş evrişim (DWRSeg) modülü; 2) Parametre sayısını azaltıp doğruluğu artıran ve orijinal alt örnekleme modülünün yerini alan ADown modülü; 3) Hesaplama verimliliği ile tespit doğruluğunu dengelemek için çok ölçekli kayan pencere dikkatine (SWDA) sahip MSDA (Multi-Scale Dilated Transformer) modülü. Halka açık DsPCBSD+ veri seti üzerinde yapılan ve ablasyon deneyleriyle doğrulanan sonuçlar, YOLOV11-DAM modelinin %86.0 mAP@50 değerine ulaştığını göstermiştir. Bu, %84.8 mAP@50 elde eden orijinal YoloV11 modeline kıyasla %1.2'lik bir artışı temsil etmektedir. Ayrıca, doğruluk (Accuracy) %85.3'e (%1.4 artış) ve mAP50-95 %53.4'e (%1.5 artış) yükselmiş, böylece modelin gerçek zamanlı verimliliği korunurken endüstriyel denetim için güvenilir bir çözüm sunduğu kanıtlanmıştır.

Li vd., 2024 [16] çalışmalarında, PCB (Baskılı Devre Kartı) yüzeylerindeki, özellikle küçük ve dağınık (small and dispersed) kusurların tespit zorluklarına ve denetimli öğrenme için gereken yüksek etiketleme maliyetlerine odaklanılmıştır. Bu sorunlara çözüm olarak, Deformable-DETR modeli temel alınarak PCB-DETR adında yeni bir tespit ağı önerilmiştir. Modelde iki temel iyileştirme yapılmıştır: 1) Farklı ölçeklerdeki öznetelik çıkarımını optimize etmek için orijinal omurga (backbone) EfficientNet ile değiştirilmiştir; 2) Küçük ve dağınık kusurları yakalamak amacıyla dikkat odağını dinamik olarak ayarlayan bir Mekansal Dikkat Ofset Modülü (Spatial Attention Offset Module) eklenmiştir. PKU-Market-PCB veri seti üzerinde yapılan kapsamlı karşılaştırmalı deneylerde, PCB-DETR, YOLOv5 (%91.7 mAP50) ve orijinal Deformable-DETR (%91.7 mAP50) gibi ana akım modellerden daha iyi performans göstermiştir. Önerilen model, %95.3 mAP50 ve %92.8 Geri Çağırma (Recall) değerlerine ulaşarak, temel modele kıyasla tespit doğruluğunda (mAP) %3.6'lık bir artış sağlamıştır. Ayrıca, çıkarım süresinin (inference time) %15.2 oranında azaltılması, modelin yüksek doğruluk ve hesaplama verimliliğini dengeleyerek gerçek zamanlı endüstriyel uygulamalar için uygun, sağlam bir çözüm sunduğunu doğrulamıştır.

Wang vd., 2025 [17] çalışmalarında, elektronik üretimindeki son derece çeşitli (diverse) ve gizlenmiş (concealed) (örn: kabarcık, dahili çip, PCB) kusurların tespiti ve tek görevli (single-task) modellerin bu karmaşık senaryolardaki yetersizlikleri ele alınmıştır. Bu zorluklara çözüm olarak, MSAN-Net (Multimodal Multi-Scale Convolution-Transformer Vision Network) adlı, çoklu-veri seti karma eğitimi (multi-dataset mixed training) temelli, tek aşamalı (single-stage) bir model önerilmiştir. MSAN-Net, CNN'lerin (yerel ayrıntı yakalama için) ve Transformer'ların (küresel semantik modelleme için) güçlerini birleştiren UnifiedViT mimarisini temel alır ve bunu C2f modülleri ve Çift Seviyeli Yönlendirme Dikkati (Bi-Level Routing Attention) mekanizmasıyla entegre eder. Dört farklı endüstriyel veri setinin birleştirilmesiyle oluşturulan "Concat Dataset" üzerinde yapılan deneylerde, MSAN-Net

0.853 AP50 ve 0.548 AP50:95 skorları elde etmiştir. Bu sonuç, YOLOv8-n (0.844 AP50) ve YOLOv11-n (0.849 AP50) gibi diğer SOTA modellerden daha üstün bir performans ve çapraz etki alanı genellemesi (cross-domain generalization) yeteneği sergileyerek, akıllı kalite denetimi için güvenilir bir çözüm sunduğunu kanıtlamıştır.

Selvam vd., 2025 [18] çalışmalarında, PCB (Baskılı Devre Kartı) yüzeylerindeki karmaşık arka planlarda (complex background) bulunan küçük boyutlu (tiny-sized) kusurların tespiti zorluğuna odaklanılmıştır. Düşük doğruluk ve verimlilik sorunlarını aşmak için YOLOv11 algoritması temel alınarak YOLO-DefXpert adlı yeni bir model önerilmiştir. Bu model dört ana iyileştirme içermektedir: 1) Modelin omurgası (backbone), daha sağlam öznetelikler çıkarmak için Swin Transformer ile değiştirilmiştir; 2) Alt örnekleme (downsampling) sırasında özellik sızıntısını (feature leakage) azaltmak için CBAM (Convolutional Block Attention Module) eklenmiştir; 3) "Boyun" (neck) kısmında, çok ölçekli kusurları tanımak için DCNv2 (Deformable Convolutional Networks) kullanılmıştır; 4) Küçük kusurları (shallow semantic information) yakalamak için Ek bir Özellik Füzyon Katmanı (AFFL) eklenmiştir. Halka açık PCB veri setleri üzerinde yapılan deneylerde, önerilen model %99.3 mAP50 ve %63.4 mAP95 elde etmiştir. Bu sonuç, YOLOv11 (%97.6 mAP50) ve YOLO-SSW (%98.4 mAP50) dahil olmak üzere diğer SOTA modellerden daha yüksek bir doğruluk sergilemiş ve 104.71 FPS ile yüksek verimlilik göstermiştir.

Ali M vd., 2025 [19] çalışmalarında, PCB (Baskılı Devre Kartı) kusur tespitinde hız, doğruluk ve bilinmeyen hata türlerine adaptasyon zorluklarını ele almak amacıyla YOLOv12 modeli temel alınarak HAYOLO adlı geliştirilmiş bir model önerilmiştir. Modelin temel yeniliği, mekansal (spatial), kanal (channel) ve koordinat (coordinate) dikkat yöntemlerini birleştiren Hiyerarşik Dikkat Füzyon Modülü'nü (HAFM) entegre etmesidir; bu sayede çok ölçekli öznetelik temsili (multi-scale feature representation) ve tespit doğruluğu artırılmıştır. Üç katlı çapraz doğrulama (three-fold cross-validation) ile eğitilen HAYOLO, yalnızca 2.2 milyon parametreye sahip hafif bir yapı sunmasına rağmen, %98.4 mAP@0.5 (%98.0 Kesinlik, %95.8 Geri Çağırma) elde etmiştir. Bu sonuç, YOLOv12m (%97.7 mAP) ve CDI-YOLO (%98.3 mAP) gibi modelleri geride bırakırken, 72 FPS ile daha yüksek bir gerçek zamanlı performans ve çok daha düşük bir parametre sayısı sunmaktadır. Çalışma, modelin "spurious_copper" ve "missing_hole" gibi düşük kontrastlı kusurlarda arka planla karışıklık yaşama gibi sınırlılıkları olduğunu belirtse de, HAYOLO'nun endüstriyel denetim için yüksek hassasiyetli ve verimli bir çözüm potansiyeline sahip olduğunu vurgulamaktadır.

Supong vd., 2024 [20] çalışmalarında, büyük PCB (Baskılı Devre Kartı) görüntülerinin, ağa sığdırmak için küçültülmesi (downsizing) sırasında yaşanan girdi bilgisi kaybı (input information loss) sorununa odaklanılmıştır. Bu zorluğun üstesinden gelmek için, yoğun veri artırma (intensive augmentation) ile geliştirilmiş kusur odaklı bir görüntü oluşturma (defect-centered image generation) yöntemi önermişlerdir; bu sayede model, kusurların ve çevresindeki ortamın ayrıntılı bilgisini öğrenebilmektedir. Bu veri stratejisi, modifiye edilmiş bir YOLOv8n mimarisi ile birleştirilmiştir. Modelin küçük kusur tespit performansını artırmak için, mimariye önemli özelliklere odaklanan CBAM (Convolutional Block Attention Module) katmanları, çok ölçekli tespit için FPN (Feature Pyramid Network) ve veri dengesizliği için Focal Loss fonksiyonu entegre edilmiştir. Benchmark veri seti üzerinde yapılan deneylerde, önerilen yöntem %99.8 mAP50 ve %99.6 Geri Çağırma (Recall) elde

ederek, YOLO-HMC (%98.5 mAP50) ve TDD-YOLO (%97.8 mAP50) gibi mevcut yaklaşımları belirgin bir şekilde geride bırakmıştır. Özellikle, "Missing hole", "Short" ve "Spurious copper" dahil altı kusur sınıfının beşinde 1.00'lık mükemmel bir AP (Average Precision) skoru elde ederek, modelin neredeyse tüm kusurları tespit etme ve çok az yanlış pozitif üretme konusunda üstün bir doğruluk sağladığı kanıtlanmıştır.

2.3. PCB Odaklı Hata Tespiti Analizi

PCB özelindeki 10 makalenin incelenmesi, bu alanın "Genel Endüstriyel Hata Tespitinden" daha spesifik ve zorlu problemlere odaklandığını göstermektedir. Temel zorluk, "küçük hedef tespiti" (tiny-sized defects) ve "karmaşık arka plan" (complex background) sorunlarıdır. İncelenen yaklaşımlarda YOLO ailesinin (v8, v9, v11, v12) neredeyse tam bir hakimiyeti görülmektedir. Araştırmacılar, standart YOLO modellerinin bu spesifik sorunları çözmede yetersiz kaldığını ve bu nedenle mimariyi modifiye etme yoluna gittiklerini göstermiştir. Öne çıkan iyileştirme yöntemleri; (1) Transformer Entegrasyonları (Swin-T, BotNet, MSDA, UnifiedViT) ile küresel bağlamın daha iyi anlaşılması, (2) Dikkat Mekanizmaları (CBAM, HAFM, Mekansal Dikkat) ile modelin küçük kusurlara odaklanmasının sağlanması, (3) Küçük Hedef Başlıkları (Additional Feature Fusion Layers) eklenerek düşük seviyeli özneteliklerin korunması ve (4) Veri Odaklı Yöntemler (örn: Kusur Odaklı Görüntü Oluşturma) ile bilgi kaybının önlenmesidir.

3. MATERYAL VE YÖNTEM


Bu çalışmada, PCB kusurlarının tespiti için derin öğrenme tabanlı bir nesne tespiti yaklaşımı benimsenmiştir. Bu bölümde, kullanılan veri setinin özellikleri, tercih edilen model mimarisi ve deneysel çalışmalarda izlenen iş akışı detaylandırılmaktadır.

3.1. Veri Seti Tanıtımı

Bu çalışmada, PCB (Baskılı Devre Kartı) yüzeylerindeki kusurların tespiti için Kaggle platformunda Norbert Elter tarafından yayınlanan halka açık "PCB Defect Dataset" başlıklı veri seti kullanılmıştır [21]. Bu veri seti, Pekin Üniversitesi İnsan-Robot Etkileşimi Açık Laboratuvarı tarafından TDD-Net çalışması için yayınlanan orijinal veri setinin artırılmış (augmented) ve YOLO formatına uyarlanmış bir versiyonudur.

Veri seti, endüstriyel üretimde karşılaşılan altı temel PCB kusur sınıfını içermektedir. Bu sınıflar; missing hole (eksik delik), mouse bite (kenar yongası), open circuit (açık devre), short (kısık devre), spur (kısık hat çıkıntısı) ve spurious copper (hat dışı bakır) olarak tanımlanmıştır.


Toplam 10.668 adet görüntü ve bu görüntülere karşılık gelen etiket (annotation) dosyalarından oluşan bu zengin veri seti, derin öğrenme modellerinin eğitimi için kritik öneme sahip olan YOLO (.txt) etiket formatında sunulmuştur. Bu format, her bir kusurun sınıfını ve sınırlayıcı kutu (bounding box) koordinatlarını (x_center, y_center, width, height) normalize edilmiş bir şekilde içerir. Veri setinin bu yapısı, projemizde kullanılan YOLO tabanlı modellerin eğitim süreçleriyle doğrudan uyumludur.



Şekil 1. Veri Setinden Örnekler

3.2. Model Mimarisi ve Ortam Hazırlığı

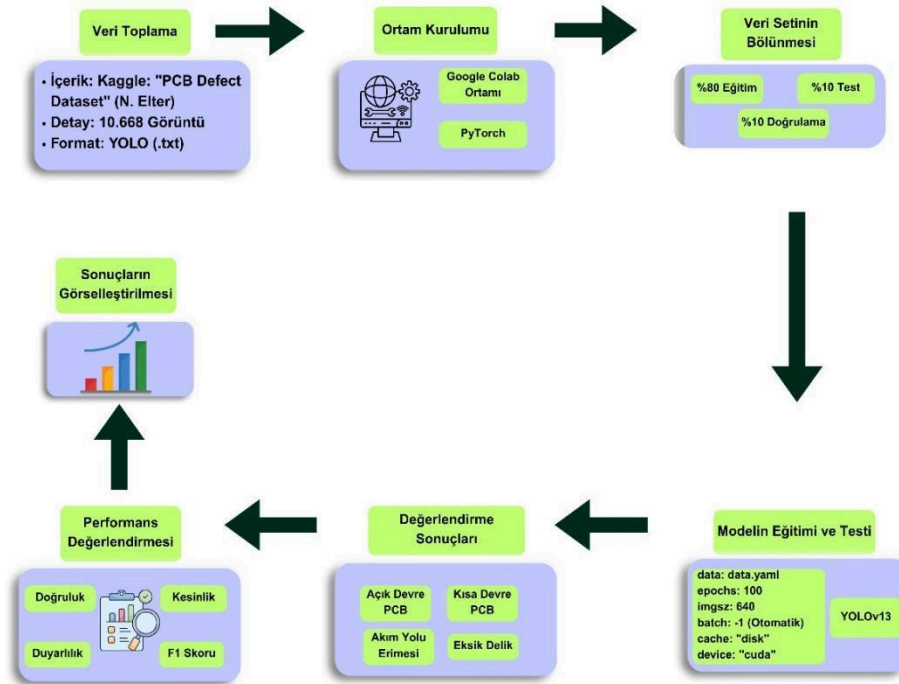
Bu çalışmada, endüstriyel PCB kusurlarının gerçek zamanlı ve yüksek doğrulukla tespit edilmesi amacıyla, nesne tespiti (object detection) alanındaki en güncel mimarilerden biri olan **YOLOv13** tercih edilmiştir. iMoonLab topluluğu tarafından geliştirilen bu model, YOLO ailesinin önceki sürümlerine kıyasla özellikle küçük nesne tespitinde (small object detection) uzmanlaşmıştır. Mimari, **HyperACE**, **A2C2f** ve **FullPAD Tunnel** gibi yeni nesil modülleri entegre ederek, PCB yüzeyindeki kırık devre yolları veya milimetrik "missing hole" gibi ince detayların öznetelik çıkarımını güçlendirmektedir.



Şekil 2 YOLO Modeli İçin Performans Kıyaslaması [22]

Modelin eğitimi ve test aşamaları **Google Colaboratory Pro+** ortamında gerçekleştirilmiştir. Hesaplama birimi olarak, büyük görüntü boyutlarını ve karmaşık model mimarisini destekleyebilecek yüksek VRAM kapasitesine sahip **NVIDIA A100 (80GB)** GPU kullanılmıştır. Çalışma ortamı hazırlanırken ilgili YOLOv13 GitHub reposu klonlanmış ve gerekli kütüphane bağımlılıkları güncel sürümleriyle yapılandırılmıştır.

Veri hazırlığı aşamasında, veri setine Google Drive üzerinden doğrudan erişimin I/O (giriş/çıkış) darboğazına yol açtığı ve eğitim süresini uzattığı gözlemlenmiştir. Bu donanımsal gecikmeyi önlemek amacıyla veri seti, sıkıştırılmış formatta Google Drive'dan alınarak Colab'ın yerel disk alanına taşınmış ve burada zipten çıkarılmıştır. Bu işlem, veri okuma hızını optimize ederek eğitim süresini önemli ölçüde kısaltmıştır. Ayrıca, YOLOv13 mimarisinin esnekliğini artırmak adına temel yapı dosyası üzerinden nano (n), small (s), large (l) ve xlarge (x) varyantları türetilmiş; projenin donanım kısıtları ve doğruluk beklentisi gözetilerek **YOLOv13s (Small)** varyantı seçilmiştir.



Şekil 3. İş Akışı diyagramı

3.3. YOLOv13 için Eğitim Süreci ve Parametreler

Model eğitimi, PCB veri setine özgü özniteliklerin sıfırdan öğrenilmesi amacıyla "from scratch" (önceden eğitilmiş ağırlıklar kullanılmadan) stratejisiyle başlatılmıştır. Eğitim sürecinde modelin genelleme yeteneğini artırmak ve donanım kaynaklarını maksimum verimle kullanmak için aşağıdaki hiper-parametreler ve stratejiler uygulanmıştır:

- Model Varyantı: Parametre sayısı ve hesaplama hızı dengesi nedeniyle YOLOv13s konfigürasyonu kullanılmıştır.
- Görüntü Boyutu (Image Size): PCB üzerindeki mikroskobik hataların kaybolmasını önlemek amacıyla, standart 640 piksel yerine daha yüksek çözünürlüklü 960x960 piksel (ve karşılaştırma için 640x640) girdi boyutu tercih edilmiştir.
- Epoch Sayısı: Modelin yakınsama (convergence) davranışı analiz edilerek eğitim 50 Epoch ile sınırlandırılmıştır.
- Batch Size: GPU belleğini (80GB VRAM) tam kapasite kullanmak için batch=-1 (AutoBatch) özelliği aktif edilmiş, sistemin donanıma en uygun paket boyutunu otomatik belirlemesi sağlanmıştır.
- Optimizasyon: Gradyan güncellemeleri için SGD (Stochastic Gradient Descent) algoritması kullanılmış, momentum=0.937 ve weight_decay=0.0005 değerleri ile modelin yerel minimumlara takılması engellenmiştir.
- Öğrenme Hızı (Learning Rate): Başlangıç öğrenme hızı lr0=0.01 olarak belirlenmiş ve Cosine Annealing (cos_lr=True) stratejisi ile eğitim boyunca dalgalı bir şekilde azaltılarak optimal noktaya ulaşılması hedeflenmiştir.
- Veri Artırma ve Mozaik: Modelin küçük nesneleri daha iyi öğrenmesi için Mozaik (Mosaic) veri artırma tekniği kullanılmış, ancak eğitimin kararlılığını artırmak için son 10 epoch'ta bu özellik (close_mosaic=10) kapatılmıştır.
- Donanım Hızlandırma: Hesaplamaların hassasiyetini korurken belleği verimli kullanmak için Karma Hassasiyet (Mixed Precision - amp=True) ve cache=True özellikleri aktif edilmiştir.

3.4. Yöntem 2: Özelleştirilmiş Sınıflandırma (ResNet-50)

Çalışmanın bu aşamasında, YOLOv13 ile gerçekleştirilen nesne tespiti yöntemine alternatif olarak, problemin sadece "sınıflandırma" boyutuna odaklanan bağımsız bir derin öğrenme modeli geliştirilmiştir. Bu yaklaşımın amacı, endüstriyel hataların tespiti (lokalizasyon) ile tanımlanması (klasifikasyon) arasındaki performans farkını analiz etmektir. Bu kapsamda, derin mimarisi ve yüksek öznitelik çıkarma kapasitesi nedeniyle **ResNet-50** modeli tercih edilmiştir.

Modelin eğitimi için YOLO'dan bağımsız, etikete dayalı bir Veri Hazırlama (Preprocessing) süreci işletilmiş olup "**Dijital Makas**" ön işleme algoritması kullanılıp şu şekilde ilerlenmiştir

- **Sorun:** Orijinal PCB görüntüleri çok yüksek çözünürlüklü olup, hatalar (örneğin bir *mouse_bite*) görselin %1'inden daha az bir alanı kaplamaktadır. Standart bir sınıflandırma ağı, bu kadar büyük bir arka plan gürültüsü (background noise) içinde hatayı öğrenmekte zorlanmaktadır.
- **Çözüm:** Etiket dosyalarındaki koordinat verileri birer referans noktası olarak kullanılmış ve her bir hata, ana görüntüden otomatik olarak kırpılarak (cropping) ayrıştırılmıştır.
- **Sonuç:** Bu işlem sonucunda, orijinalde 8.500 adet olan ham veri seti, bir kartta birden fazla hata bulunabildiği için zenginleşerek **12.991** adet saf hata görüntüsüne (Eğitim Seti) ve **1.595** adet doğrulama görüntüsüne (Validasyon Seti) dönüştürülmüştür. Bu strateji, modelin sadece hataya odaklanmasını sağlayarak öğrenme verimliliğini maksimize etmiştir.

3.5. Eğitim Konfigürasyonu ve Hiperparametreler (ResNet)

Model eğitimi, Transfer Öğrenme (Transfer Learning) stratejisi temel alınarak kurgulanmıştır. ImageNet veri seti üzerinde önceden eğitilmiş ağırlıklarla başlatılan ResNet-50 mimarisi üzerinde, "Kısmi Dondurma" (Partial Freezing) tekniği uygulanmıştır:

1. **Dondurulan Katmanlar:** Modelin ilk 140 katmanı dondurularak (trainable=False), kenar, köşe ve temel geometrik şekilleri tanıyan evrensel görme yetisi korunmuştur.
2. **Eğitilen Katmanlar:** 140. katmandan sonraki bloklar serbest bırakılarak, modelin PCB yüzey dokusunu, bakır yollarını ve lehim hatalarını öğrenmesi sağlanmıştır.

Modelin çıkış katmanına, probleme özgü bir Özel Sınıflandırıcı Bloğu (Custom Classifier Head) entegre edilmiştir. Bu blok sırasıyla; öznitelik haritalarını vektöre dönüştüren GlobalAveragePooling2D, veri dağılımını dengeleyen BatchNormalization, 512 nöronlu Dense (ReLU) katmanı ve ezberlemeyi (overfitting) önleyen Dropout (0.4) katmanından oluşmaktadır.

Eğitim sürecinde modelin stabilitesini sağlamak için şu hiper-parametreler kullanılmıştır:

- Optimizasyon: Adaptif moment tahmini sunan Adam optimizasyon algoritması.
- Öğrenme Hızı (Learning Rate): Transfer öğrenme yapıldığı için, var olan ağırlıkları bozmamak adına standart değerden 100 kat daha düşük olan $1e-5$ (0.00001) değeri seçilmiştir.
- Epoch: Modelin yaklaşık 20. turda doygunluğa (convergence) ulaştığı gözlemlenmiş, eğitim 30 Epoch sonunda tamamlanmıştır.
- Callbacks (Eğitim Sigortaları):

- ModelCheckpoint: Sadece doğrulama başarısının arttığı durumlarda ağırlıklar kaydedilmiştir.

-ReduceLROnPlateau: İyileşme durduğunda öğrenme hızı otomatik olarak %20'sine (factor=0.2) düşürülerek hassas ayar yapılmıştır

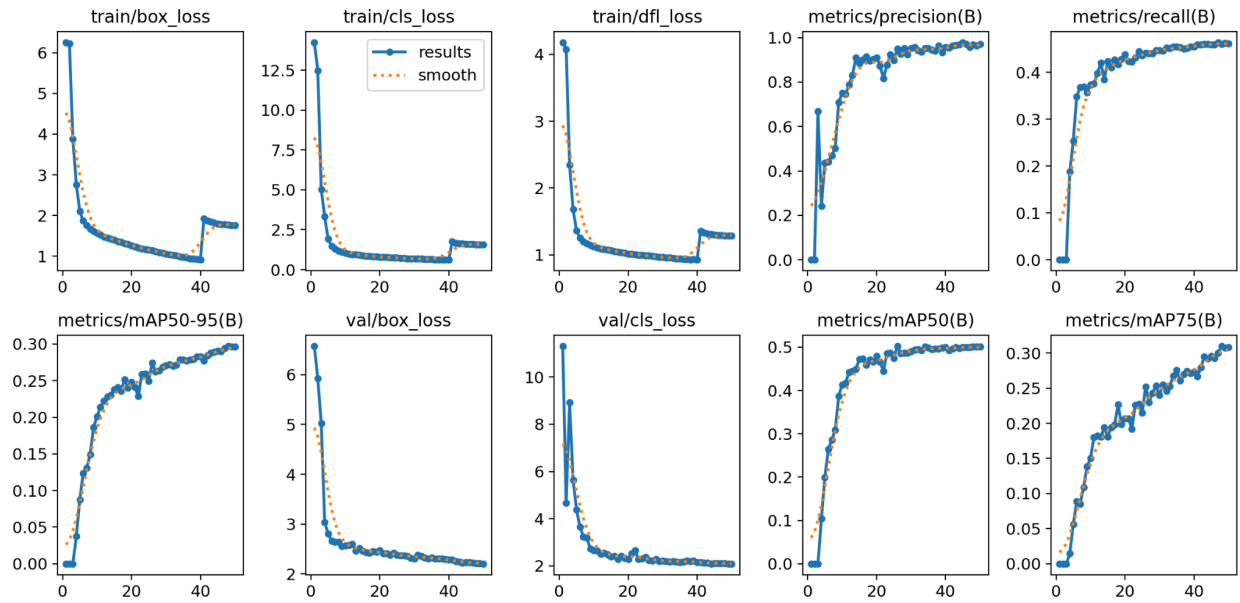
-EarlyStopping: Aşırı öğrenmeyi engellemek için gelişim durduğunda eğitim erken sonlandırılmıştır.

4. DENEYSEL SONUÇLAR

Bu bölümde, PCB yüzey hatalarının tespiti için geliştirilen YOLOv13 (Nesne Tespiti) ve ResNet-50 (Sınıflandırma) modellerinin eğitim ve test aşamalarında elde ettikleri performans verileri nicel ve görsel olarak analiz edilmiştir.


4.1. YOLOv13 Sonuçları (Nesne Tespiti Performansı)

YOLOv13s modeli, iki farklı giriş çözünürlüğü (640x640 ve 960x960 piksel) ile 50 epoch boyunca eğitilmiştir. Eğitim sürecine ait metrikler ve doğrulama seti üzerindeki hata matrisleri Şekil 4. ve Şekil 4.1 de verilmiş olup, değerlendirilmiştir.



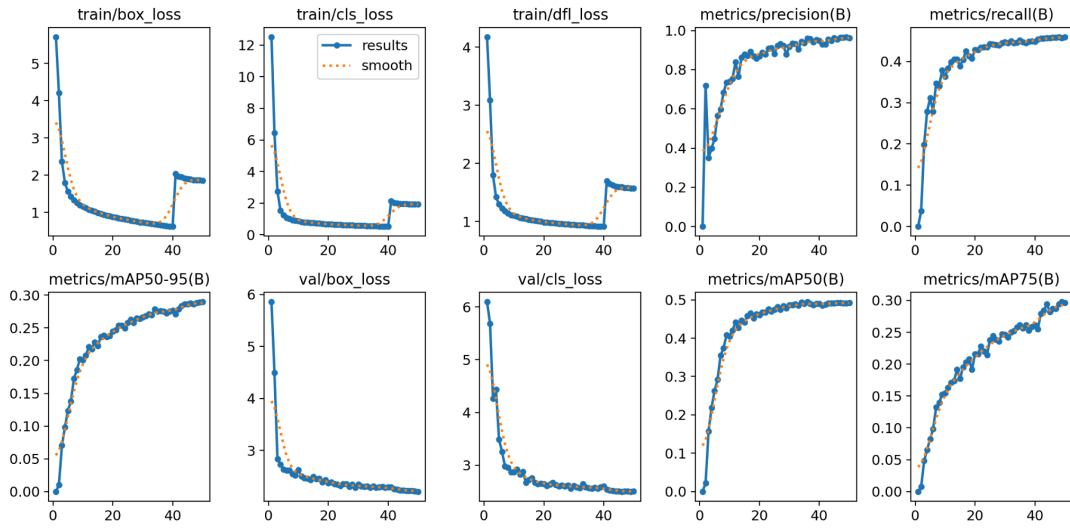
Şekil 4. 640x640 Eğitim Süreci Metrikleri

Eğitim Grafikleri Analizi: Eğitim kaybı (Box & Cls Loss) istikrarlı bir düşüş göstermiş, ancak 40. epoch'ta mozaik veri artırmanın kapatılmasıyla (close_mosaic) beklenen bir sıçrama yaşanmış ve ardından model stabilize olmuştur. Kesinlik (Precision) 0.95 seviyelerine çıkarak modelin bulduğu hatalarda çok emin olduğunu göstermiştir. Ancak Duyarlılık (Recall) 0.50 bandında tıkanmış, yani model hataların sadece yarısını yakalayabilmiştir.




Şeki 4.1 640x640 Confusion Matrisi

Hata Matrisi Analizi: 640x640 piksel matrisi incelendiğinde, modelin en büyük probleminin "Background" (Arka Plan) hatası olduğu görülmektedir. Örneğin Spur (Çapak) sınıfında; model 144 adet hatayı doğru tespit etmiş, ancak 224 adet gerçek hatayı "Arka Plan" (hata yok) zannederek kaçırmıştır. Benzer şekilde Short (Kısa Devre) hatalarının 195'i kaçırılmıştır. Bu durum, 640 piksel çözünürlüğün milimetrik hataları görünür kılmakta yetersiz kaldığını düşündürmektedir.



Şekil 4.2 960x90 Eğitim Süreci Metrikler

Eğitim Grafikleri Analizi, çözünürlüğün artırılması, eğitim süresini uzatmasına rağmen mAP50 ve Recall değerlerinde dramatik bir iyileşme sağlamamıştır. Grafikler, 640 piksel deneyine çok benzer bir trend izlemiş; Recall değeri yine 0.50 seviyelerinde kalmıştır. Bu durum, sorunun sadece piksel çözünürlüğü olmadığını, arka plan karmaşıklığının modelin kafasını karıştırdığını göstermektedir.



Şeki 4.3 960x960 Confusion Matris

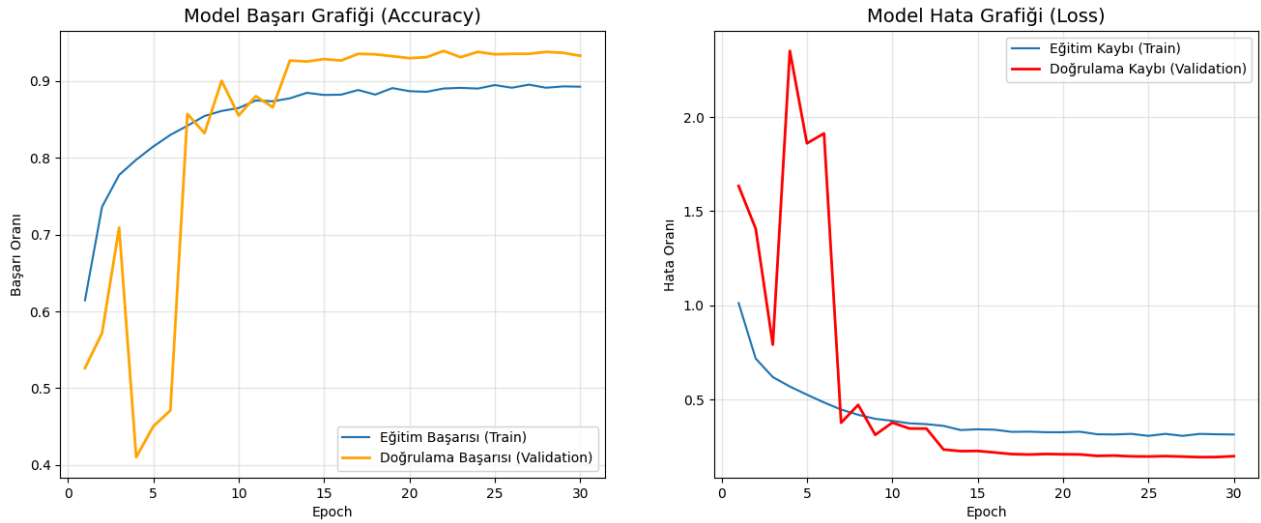
Hata Matrisi Analizi: 960 piksel matrisindeki sayılar, çözünürlük artışının tespit oranına marjinal bir etkisi olduğunu doğrulamaktadır. Mouse Bite sınıfında doğru tespit sayısı 175'ten (640px) 174'e (960px) düşmüş, gözden kaçan (Background) sayısı 198 olmuştur. Missing Hole sınıfında da doğru tespit sayısı 149 olarak sabit kalmıştır.

4.1.2. YOLOv13 Genel Değerlendirmesi

Her iki deneyin sonuçları karşılaştırıldığında, YOLOv13 modelinin yüksek kesinlik (High Precision) ancak düşük duyarlılık (Low Recall) karakteristiği sergilediği görülmüştür. Model, tespit ettiği hatalarda %90 üzerinde doğruluk sağlasa da, hataların yaklaşık %50'sini "Arka Plan" olarak sınıflandırarak gözden kaçırmaktadır. Çözünürlük artışı bu yapısal sorunu çözmekte yeterli olmamıştır.

4.2. ResNet-50 DeneySEL Sonuçları (Bağımsız Sınıflandırma)


Özelleştirilmiş ResNet-50 modeli, "Dijital Makas" yöntemiyle elde edilen 12.991 adet eğitim görüntüsü üzerinde 30 epoch boyunca eğitilmiştir. Modelin sınıflandırma performansına dair grafikler ve hata analizleri aşağıda sunulmuştur.



Şekil 4.4 Accuracy/Loss Grafikleri

Eğitim Dinamiği: Grafiklerdeki en dikkat çekici nokta, eğitimin ilk evrelerinde (4. ve 5. epoch civarı) Doğrulama Kaybında (Validation Loss) yaşanan ani yükseliş ve ardından gelen hızlı toparlanmadır. Bu dalgalanma, transfer öğrenme sürecinde modelin yeni veri setine adaptasyon sancısıdır. Ancak, kullanılan ReduceLROnPlateau mekanizması ve BatchNormalization katmanları sayesinde model hızla stabilize olmuş ve 12. epoch'tan itibaren kayıp değeri 0.2 bandına oturmuştur.

Başarı Oranı: Eğitim ve doğrulama başarı eğrileri (Train vs Validation Accuracy) birbirine paralel ve yakın seyretmiştir. Bu durum, modelde ezberleme (overfitting) probleminin olmadığını gösterir. Sonuç olarak model, doğrulama setinde %93.92 gibi yüksek ve güvenilir bir doğruluk oranına ulaşmıştır.



Şekil 4.4 Accuracy/Loss Grafikleri

Modelin 6 farklı hata sınıfını ayırt etme performansı, doğrulama seti üzerindeki Karmaşıklık Matrisi ile analiz edilmiştir:

1- Genel Ayırım Gücü: Matrisin köşegen (diagonal) üzerindeki yüksek değerler, modelin sınıflandırma başarısını kanıtlamaktadır.

- Missing Hole (Eksik Delik): Modelin en başarılı olduğu sınıftır. Toplam 229 test verisinden 228 tanesini doğru bilerek %99.6 başarı sağlamıştır.
- Short (Kısa Devre): 301 adet doğru tespit ile en yüksek doğru sayıya ulaşılan sınıflardan biridir.

2- Hata Kümeleri: Modelin en çok karıştırdığı iki sınıf Spur (Çapak) ve Spurious Copper (Fazla Bakır) olmuştur. Matriste görüldüğü üzere; gerçekte Spur olan 15 örnek Spurious Copper olarak, gerçekte Spurious Copper olan 6 örnek ise Spur olarak tahmin edilmiştir.

5. GENEL DEĞERLENDİRME

Bu çalışmada, PCB yüzey hatalarının tespiti problemi, endüstriyel uygulanabilirlik ve doğruluk perspektifinden iki farklı derin öğrenme mimarisi (ResNet-50 ve YOLOv13) üzerinden ele alınmıştır. Elde edilen deneysel sonuçlar, sadece modellerin başarısını değil, aynı zamanda üretim hattı (production line) gereksinimlerine uygun mimari seçiminin önemini de ortaya koymuştur.

5.1. Test Edilen İki Temel Yaklaşım

1. ResNet-50 (Sınıflandırma Odaklı - Hibrit Yaklaşım):

Bu deneyde, hataların görsel karakteristiğinin makine tarafından öğrenilebilir olup olmadığını doğrulamak amacıyla Transfer Öğrenme (Transfer Learning) yöntemi uygulanmıştır.

Bulgu: Modelin %94 doğruluk oranına ulaşması, PCB hatalarının (çapak, eksik delik vb.) yeterli öznetelik bilgisine sahip olduğunu ve derin ağlar tarafından ayırt edilebildiğini kanıtlamıştır.

2. YOLOv13 (Tespit Odaklı - One Stage Yaklaşım):

Projenin nihai hedefi olan "otonom denetim" için, hatanın hem sınıfını hem de konumunu ve kordinatları tek seferde bulabilen YOLOv13 mimarisi kullanılmıştır.

5.2. Kritik Mimari Kararı: Neden ResNet Tabanlı Dedektör Seçilmedi?

Literatürde ResNet-50, genellikle Faster R-CNN gibi güçlü nesne tespit modellerinin omurgası (backbone) olarak kullanılmaktadır. Proje aşamasında "Neden ResNet-50 omurgalı bir Faster R-CNN kullanılmadı?"

- **Çift Aşamalı (Two-Stage) Yapı Sorunu:** Faster R-CNN gibi yapılar, önce Bölge Öneri Ağı (RPN - Region Proposal Network) ile "burada bir şey olabilir" adaylarını çıkarır, ardından sınıflandırma yapar.
- **Dezavantaj:** Bu RPN katmanı ve çift aşamalı işlem süreci, hesaplama maliyetini ciddi oranda artırır. Bir PCB üretim bandında saniyede onlarca kartın geçtiği senaryoda (Real-Time), çift aşamalı dedektörlerin işlem hızı (FPS - Frame Per Second) darboğaz oluşturmaktadır.

5.3. Seçilen Mimari ve Sonuç: YOLOv13

Yapılan analizler sonucunda, endüstriyel kalite kontrol süreçlerinin "Hız ve Doğruluk Dengesi" gereksinimi nedeniyle asıl model olarak YOLOv13 tercih edilmiştir.

- **Tek Aşamalı (One-Stage) Üstünlüğü:** YOLO mimarisi, RPN katmanına ihtiyaç duymaz. Görüntüyü tek bir sinir ağı geçişiyle (Single Shot) tarayarak hem nesne yerini hem de sınıfını aynı anda tahmin eder.
- **Gerçek Zamanlı (Real-Time) Çalışma:** Deneysel sonuçlarımızda, YOLOv13'ün ResNet tabanlı dedektörlere kıyasla çok daha yüksek FPS değerlerine ulaşabileceği ve milimetrik hataları (özellikle yüksek çözünürlükte) tespit edebilecek kapasitede olduğu görülmüştür.

Sonuç olarak; ResNet-50 deneyi, veri setimizin sınıflandırılabilir olduğunu doğrulayan bir "fizibilite testi" (Proof of Concept) olarak başarıyla tamamlanmış; ancak projenin nihai çözümü, gerçek zamanlı çalışma yeteneği nedeniyle YOLOv13 olarak belirlenmiştir.

KAYNAKÇA

- [1] Ding, R., Dai, L., Li, G., & Liu, H. (2019). TDD-net: a tiny defect detection network for printed circuit boards. *CAAI Transactions on Intelligence Technology*, 4(2), 110-116.
- [2] Al-Jumaili, M. S. (2025, April). The Impact of AI on Enhancing the Quality of Digital Industrial Products. In *2025 IEEE 4th International Conference on Computing and Machine Intelligence (ICMI)* (pp. 1-5). IEEE.
- [3] Hsu, J. C., Su, P. C., Huang, C. W., & Lin, Y. A. (2025, January). DA-SAM: A Defect-Aware Segmentation Model for Industrial Product Inspection. In *2025 IEEE International Conference on Consumer Electronics (ICCE)* (pp. 1-3). IEEE
- [4] Butolo, M., Stanciu, A., Goga, N., Dinu, B., Popa, R. C., Anton, H., ... & Perino, B. C. (2024, September). Advanced Real-Time Surface DefectDetection in Industrial Products Using Machine Vision. In *2024 IEEE SmartBlock4Africa* (pp. 1-6). IEEE.
- [5] Li, Z., Zhang, Z., Ma, J., & Tian, L. (2023, August). Improved YOLOV5 based industrial surface defect detection method. In *2023 International Conference on Computers, Information Processing and Advanced Education (CIPAE)* (pp. 367-370). IEEE.
- [6] Huang, Y., Liu, B., Dong, H., Lu, B., Jiang, Y., & Liu, G. (2023, May). A Novel Weakly Supervised Learning Method for Industrial Surface Defect Detection. In *2023 6th International Conference on Artificial Intelligence and Big Data (ICAIBD)* (pp. 741-745). IEEE.
- [7] Zhu, Z., Zhu, P., Zeng, J., & Qian, X. (2022, June). A surface fatal defect detection method for magnetic tiles based on semantic segmentation and object detection: IEEE ITAIC (ISSN: 2693-2865). In *2022 IEEE 10th joint international information technology and artificial intelligence conference (ITAIC)* (Vol. 10, pp. 2580-2586). IEEE.
- [8] Luo, B., Wang, H., Jia, J., Qin, N., Du, Y., & Xie, L. (2023, September). Defect detection of metal sheets based on improved yolox algorithm. In *2023 CAA Symposium on Fault Detection, Supervision and Safety for Technical Processes (SAFEPROCESS)* (pp. 1-6). IEEE.
- [9] Deng, J., & Mao, G. (2025, July). AF Det: An Attention Fusion Convolutional Network for High Fidelity Industrial Defect Detection. In *2025 4th International Conference on Robotics, Artificial Intelligence and Intelligent Control (RAIIC)* (pp. 91-94). IEEE.
- [10] Yang, Q. (2025, March). Research on Aluminum Profile Surface Defect Detection Based on YOLOv11. In *2025 5th International Conference on Artificial Intelligence and Industrial Technology Applications (AIITA)* (pp. 820-823). IEEE.
- [11] Xin, S., Zhao, C., & Sun, Y. (2021, May). A machine vision-based fabric defect detection solution for textile production industry using object detection. In *2021 33rd Chinese Control and Decision Conference (CCDC)* (pp. 3656-3661). IEEE.
- [12] Xie, B., & Luo, M. (2025, April). Research on PCB Defect Detection Based on Yolo Algorithm. In *2025 6th International Conference on Computer Engineering and Application (ICCEA)* (pp. 01-05). IEEE.
- [13] Yu, J., & bin Gao, Y. (2024, October). Defect Detection on PCB Bare Boards Based on Improved YOLOv8 Algorithm. In *2024 3rd International Conference on Cloud Computing, Big Data Application and Software Engineering (CBASE)* (pp. 526-529). IEEE.

- [14] Raj, A., & Ahlawat, P. (2024, December). Refined YOLOv8 for Enhanced Small Object Detection in PCB Defect. In *2024 IEEE International Conference on Intelligent Signal Processing and Effective Communication Technologies (INSPECT)* (pp. 1-6). IEEE.
- [15] Yu, J., Hou, C., Tang, Z., & Chen, C. (2025, July). Research on PCB Defect Detection Algorithm Based on Improved YoloV11. In *2025 4th International Conference on Electronics, Integrated Circuits and Communication Technology (EICCT)* (pp. 446-449). IEEE.
- [16] Li, Q., Wu, L., Xiao, H., & Huang, C. (2024). PCB-DETR: A detection network of PCB surface defect with spatial attention offset module. *IEEE Access*.
- [17] Wang, Z., Luo, M., Xie, X., Sun, Y., Tian, X., Chen, Z., ... & Tan, T. (2025). MSAN-Net: An End-to-End Multi-Scale Attention Network for Universal Industrial Defect Detection. *IEEE Access*.
- [18] Selvam, P., Rajasekar, R., Gunasundari, C., Priya, S. J., Murugappan, M., & Chowdhury, M. E. (2025). YOLO-DefXpert: An Advanced Defect Detection on PCB Surfaces Using Improved YOLOv11 Algorithm. *IEEE Access*.
- [19] A. M. Elhenidy, R. Gaib, S. M. BAlsabti and L. R. Al-Najjar, "HAYOLO: A novel object detection model for detecting defects in PCB," in *2025 4th International Conference ...*, Publisher: IEEE.
- [20] Supong, T., Kangkachit, T., & Jitkongchuen, D. (2024, August). PCB Surface Defect Detection Using Defect-Centered Image Generation and Optimized YOLOv8 Architecture. In *2024 5th International Conference on Big Data Analytics and Practices (IBDAP)* (pp. 44-49). IEEE.
- [21] Elter, N. (2023). PCB Defect Dataset. Kaggle.
- [22] Lei, M., Li, S., Wu, Y., Hu, H., Zhou, Y., Zheng, X., ... & Gao, Y. (2025). YOLOv13: Real-Time Object Detection with Hypergraph-Enhanced Adaptive Visual Perception. *arXiv preprint arXiv:2506.17733*.